CheatSheet di Ricerca Operativa e Pianificazione delle Risorse

Fabio Ferrario

@fefabo

2022/2023

Indice

1	Gli	esercizi d'esame	3
2	Pro	grammazione Lineare	4
	2.1	Il metodo del Simplesso	4
		2.1.1 Due Fasi	6
	2.2	Dualitá	7
		2.2.1 Passare da Primale a Duale	
	2.3	Gli Scarti Complementari	8
	2.4	Esercizi su Analisi di Sensitività	8
3	Bra	${ m anchAndBound}$	10
4	Ott	imizzazione Non Lineare	11
	4.1	Risoluzione analitica per PNL Multivariati	11
		4.1.1 Matrice definita positiva/negativa	11
	4.2	Algoritmo del Gradiente	11
	4.3	Algoritmo di Newton (Multivariato)	
5	Ott	imizzazione Non Lineare Vincolata	14
	5.1	Funzione Lagrangiana	14
	5.2	Condizioni KKT	
		5.2.1 Differenziare tra Max e Min	
		5.2.2 Risolvere il Sistema	
		5.2.3 Trovare i punti di Minimo e Massimo	16

Gli esercizi d'esame

Gli esercizi possibile all'esame sono:

- Metodo del Simplesso e Due Fasi
- Scarti Complementari
- Analisi di Sensitività
- Branch and Bound per PLI o PLB
- Risoluzione Analitica di PNL Multivariato
- Metodo del Gradiente
- Algoritmo di Newton
- Condizioni KKT

Oltre a varie possibili domande di teoria.

Programmazione Lineare

2.1 Il metodo del Simplesso

La forma Tabellare

V. BASE	Eq	Z	x_1	x_2		x_n	T. Noto
Z	R_0	1	c_1	c_2		c_n	0
x_1	R_1	0	a_{11}	a_{12}		a_{1n}	b_1
:	:	:	i	:	٠	÷	:
x_m	R_n					a_{mn}	b_m

Forma Aumentata Per portare il problema in forma aumentata:

	Minoreuguale	<	=	+ Slack	
Vincoli	Maggioreuguale		e ≥	=	- Surplus
	Uguale	=	= Invariato		
Variabili non positive	$x_i \le 0$	$x_i = -x_i' \text{ con } x_i' \ge 0$			
_		parizione di x_i vie	ne sost	tituit	$\tan \cos -x_{i}^{'}$
Funzione Obiettivo	$Z = \Sigma s$	$c_i \rightarrow$	\overline{Z}	$-\Sigma x_i = 0$	

Test di Ottimalità Una volta portato il problema in forma tabellare, eseguo il test di ottimalitá:

Tipo di Problema	Massimo	Minimo	
Soluzione Ottima sse	Coefficienti riga (0) ≥ 0	Coefficienti riga (0) ≤ 0	

Nuova Soluzione di Base Una volta verificato che la soluzione non é ottima, bisogna calcolare una nuova soluzione di base:

Definisco:

Tipo di Problema	Massimo	Minimo	
Variabile Entrante (Colonna Pivot)	Coefficiente riga (0) più Piccolo (Più Negativo)	Coefficiente riga (0) più Grande (Più Positivo)	
Variabile Uscente (Riga Pivot)	Test del Rapporto Minimo		
Numero Pivot	Intersezione Riga/Colonna Pivot		

Per la nuova Riga Pivot					
Variabile di Base	\rightarrow	Variabile Entrante.			
Coefficienti e Termine Noto	\rightarrow	Divisi per Numero Pivot.			

	per ogni altra Riga					
Definisco	P_i i-esimo coefficiente della nuova riga pivot					
Demnisco	X_p coefficiente della colonna pivot nella riga in esame.					
	il coefficiente i-esimo x_i della riga in esame X diventa:					
$X_p > 0$	$X_p > 0 x_i := x_i - X_p \cdot P_i$					
$X_p < 0 x_i := x_i + X_p \cdot P_i$						
$X_p = 0$	La riga in esame resta Invariata					

2.1.1 Due Fasi

Funzione Obiettivo: Somma di tutte le variabili artificiali introdotte. (min $z = \Sigma y_i \implies \max z = -\Sigma y_i \implies \max z + \Sigma y_i = 0$) Vincoli: Per ogni vincolo che viene violato dalla soluzione Origine, sommo una variabile artificiale (unica) con coefficiente 1.

Tableau iniziale: Le variabili artificiali devono essere in base, quindi devo azzerarle in R(0) sottraendogli il vincolo a cui sono associate.

Una volta fatte entrare in base tutte le variabili artificiali, posso iterare normalmente.

Finito di iterare, avró tutte le variabili artificiali =1 in (0), rimuovo quindi le colonne artificiali e ripristino la funzione obiettivo.

Adesso faccio entrare in base (nello stesso modo di prima) le variabili che devono essere in base. poi itero normalmente.

2.2. DUALITÁ 7

2.2 Dualitá

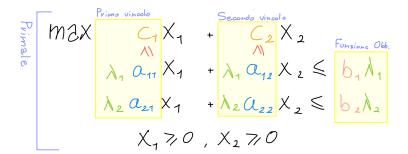
2.2.1 Passare da Primale a Duale

	Primale	Duale	Ritorno
Funzione Obiettivo	$\max c^T x$	$\min b^T \lambda$	$\max c^T x$
	$x_i^T a \le c$	$\lambda_i \ge 0$	$x_i^T a \le c$
Vincoli ⇒ Non Negativitá	$x_i^T a \ge c$	$\lambda_i \le 0$	$x_i^T a \ge c$
	$x_i^T a = c$	λ_i Free	$x_i^T a = c$
	$x_j \ge 0$	$\lambda_j^T a \ge c$	$x_j \ge 0$
Non Negatività \Longrightarrow Vincoli	$x_j \le 0$	$\lambda_j^T a \le c$	$x_j \le 0$
	x_j Free	$\lambda_j^T a = c$	x_j Free

Metodo con le matrici Un trucco per generare rapidamente il duale é utlizzare le matrici:

Avendo il seguente problema di PL:

si riconoscono opportunamente gli elementi che compongono il duale:



Che come problema duale generano:

min
$$b_1 \lambda_1 + b_2 \lambda_2$$

 $a_{11} \lambda_1 + a_{21} \lambda_1 \gg c_1$
 $a_{12} \lambda_2 + a_{22} \lambda_2 \gg c_2$
 $a_{17} a_{17} a_{17}$

2.3 Gli Scarti Complementari

Se abbiamo una soluzione ammissibile per il primale possiamo verificarne l'ottimalità tramite le condizioni degli scarti complementari: Quindi, data x^* :

$x_i^* \neq 0$	i-esimo (corrispondente) vincolo del duale attivo.
i-esimo vincolo del primale NON attivo	$\lambda_i = 0$
1-esimo vincolo del primare ivolvattivo	$\lambda_i = 0$

Pongo quindi a sistema le equazioni trovate per trovare la soluzione corrispondente del Duale. Se i valori delle funzioni obiettivo sono uguali, allora le due soluzioni sono entrambe ottime.

2.4 Esercizi su Analisi di Sensitività

Analisi sui termini noti Se si chiede di fare l'analisi di sensitività di un termine noto (b_i) della *i*-esima equazione di vincolo, dato il tableu dell'ultima iterazione:

- 9
- $\bullet\,$ Trovo la variabile di Slack della i-esima equazione di vincolo.
- Per ogni Riga del tableau in cui il coefficiente della variabile di slack è $\neq 0$ faccio:

 $\text{T.Noto} + (\text{Coefficiente della variabile di slack} \cdot \Delta) \geq 0$

• Metto a sistema le disequazioni trovate e risolvo per Delta.

BranchAndBound

I problemi di Branch and Bound si risolvono in questo modo:

- Apro il nodo k e risolvo il rilassamento lineare:
 - Aggiorno Z* se la soluzione è intera (binaria)
 - Fisso il mio Upper(Lower) Bound come l'arrotondamento (se necessario) della soluzione.
- Prendo la variabile frazionaria (o il primo indice se binario) e ne "vincolo" le soluzioni
- Elaboro tutti i nodi fino a che non si chiudono.

Ottimizzazione Non Lineare

4.1 Risoluzione analitica per PNL Multivariati

Per risolvere analiticamente un problema di PNL multivariato:

- Controllo tutti i punti in cui $\nabla f = 0$
- Per ognuno di questi punti, se:
 - -Hf nel punto è definita positiva allora è minimo.
 - Hf nel punto è definita negativa allora è massimo.
 - -Hf non è né l'uno né l'altro allora è punto di sella.

4.1.1 Matrice definita positiva/negativa

Per verificare se una matrice è positva o negativa, trovo gli autovalori sottraendo λ dalla diagonale di H valutata nel punto, e poi ponendo $det(H_{\lambda}) = 0$. per una matrice 2x2 il calcolo è: $(a_{11} - \lambda) \cdot (a_{22} - \lambda) - (a_{12} \cdot a_{21})$ Se tutti gli autovalori sono ≥ 0 allora H nel punto è (semi) definita positiva, mentre è (semi) definita negativa se gli autovalori sono ≤ 0 .

4.2 Algoritmo del Gradiente

Data una funzione a piú variabili f(X) e un punto x^0 , ogni passo del metodo del gradiente si effettua in questo modo:

1. Calcolo
$$d^k = \pm \nabla f(x^k)$$
 (+ max e - min)

- 2. Calcolo $x^{k+1} = x^k \pm \alpha^k \cdot d^k$
- 3. Calcolo α^k come $Max\ f(x^k \pm \alpha^k \cdot d^k)$. ovvero valuto f nel nuovo punto e massimizzo (minimizzo per i problemi di minimo) la funzione risultante $g(\alpha)$, generalmente in modo analitico ($g'(\alpha) = 0$)
- 4. Sostituisco α trovato in x^{k+1} .
- 5. Valuto i criteri di arresto

Per verificare che il punto trovato sia un punto di ottimo, semplicemente controllo che $\nabla f(x^*) = 0$.

Nuovo punto	x^{k+1}	$x^k \pm \alpha^k \cdot d^k$
Direzione di Crescita	d^k	$\pm \nabla f(x^k) \ (+ \max e - \min)$
Step Size	α^k	$\max/\min f(x^k \pm \alpha^k \cdot d^k)$

13

4.3 Algoritmo di Newton (Multivariato)

Data una funzione a piú variabili f(X) e un punto x^0 , una iterazione del metodo di Newton si effettua in questo modo:

- 1. Calcolo $\nabla f(x^k)$ e $H(x^k)$.
- 2. Calcolo V Vettore Spostamento: $H_f(x^k)V = -\nabla f(x^k)$ è un sistema di equazioni, risolvo per $v_1,...,v_n$
- 3. trovo $x^{k+1} = x^k + V$, in cui V é il vettore spostamento.

Vettore Spostamento	V	$H_f(x^k)V = -\nabla f(x^k)$
Nuovo punto	x^{k+1}	$x^k + V$

Ottimizzazione Non Lineare Vincolata

5.1 Funzione Lagrangiana

In un problema di ottimizzazione vincolata definito come:

opt
$$f(x_1,...,x_n)$$
,
 $g_m(x_1,...,x_n) = 0$ Vincoli di Uguaglianza,
 $h_l(x_1,...,x_n) \leq 0$ Vincoli di Disguaglianza,

Generiamo la Lagrangiana cosí definita:

$$L(V) = f(X) \pm \sum_{i=0}^{m} \lambda_i \cdot g_i(X) \pm \sum_{j=0}^{l} \mu_j \cdot h_j(X)$$

in cui \pm diventa + per i problemi di MIN e – per i problemi di MAX, Abbiamo che λ sono i moltiplicatori lagrangiani associati ai vincoli di Uguaglianza, e μ quelli associati ai vincoli di Disuguaglianza.

con $V=\{x_1,...,x_n,\lambda_1,...,\lambda_m,\mu_1,...,\mu_l\}$, ovvero tutte le variabili e $X=\{x_1,...,x_n\}$, ovvero tutte le variabili originiali.

5.2 Condizioni KKT

Tabella Bisogna quindi generare un sistema che avrá n + m + l incognite utilizzando le KKT, riportate qui in modo semplificato:

Stazionarietá Problemi di MIN (-)				
$\nabla f = -\sum \lambda_i \cdot \nabla g_i - \sum \mu_j \cdot \nabla h_j$				
Stazionarietá Problemi di MAX (+)				
$\nabla f = +\sum \lambda_i \cdot \nabla g_i + \sum \mu_j \cdot \nabla h_j$				
Ammissibilitá Vincoli Uguaglianza	$\forall \qquad g_i = 0$			
Ammissibilitá Vincoli Disuguaglianza	$\forall \qquad h_j \le 0$			
Condizione di Complementarietá	$\forall \qquad \qquad \mu_j \cdot h_j = 0$			
Non Negativitá di μ	$\forall \qquad \qquad \mu_j \geq 0$			

Dove con ∀ si intende chiaramente tutti quelli presenti.

5.2.1 Differenziare tra Max e Min

Quando si usano le KKT bisogna differenziare tra problemi di Max e Problemi di Min. Ogni problema ha le seguenti possibili combinazioni:

min com brosieme ne ic scorem bessiam comamentum.		
Problema di Massimo	$\mu_i \ge 0$	$\nabla f = +\sum \lambda_i \cdot \nabla g_i + \sum \mu_j \cdot \nabla h_j$
	$\mu_i \le 0$	$\nabla f = -\sum \lambda_i \cdot \nabla g_i - \sum \mu_j \cdot \nabla h_j$
Problema di Minimo	$\mu_i \ge 0$	$V f = \sum_{i} \lambda_i \cdot V g_i = \sum_{i} \mu_j \cdot V h_j$
	$\mu_i \le 0$	$\nabla f = +\sum \lambda_i \cdot \nabla g_i + \sum \mu_j \cdot \nabla h_j$

é utile sapere che se scegliessimo di avere la funzione obiettivo **Sempre come** somma di elementi negativi, sia per i problemi di massimo che di minimo, allora potremmo, in base ai valori di μ , sapere in un solo calcolo se il punto é candidato a massimo o minimo.

5.2.2 Risolvere il Sistema

Per risolvere il sistema, o lo si risolve con il metodo classico, oppure tramite questo metodo: Con la condizione di **Complementarietá** sappiamo che:

$$\mu_j \cdot h_j = 0 \implies \mu_j = 0 \lor h_j = 0$$

Quindi, con l variabili μ_j abbiamo 2^l combinazioni di sistemi, in cui $\mu_j = 0 \lor \mu_j \neq 0$. Cosí possiamo risolvere le 2^l combinazioni per trovare tutti i punti candidati.

5.2.3 Trovare i punti di Minimo e Massimo

I punti trovati dalle condizioni KKT sono solo candidati a essere punti di max/min, perché le KKT sono condizioni Necessarie ma non Sufficienti.

Le condizioni KKT diventano Sufficienti se:

- Per i Punti di Massimo:
 - -f é concava.
 - I vincoli $h_i(X)$ sono tutti Convessi.
- Per i Punti di Minimo:
 - $-\ f$ é convessa.
 - I vincoli $h_i(X)$ sono tutti Convessi.